

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МОЭВМ

КУРСОВАЯ РАБОТА
по дисциплине «Алгоритмы и структуры данных»
Тема: Исследование структур: АВЛ-дерево и Хеш-таблица (двойное
хеширование)

Студент гр. 1303

Кузнецов Н.А.

Преподаватель

Иванов Д.В.

Санкт-Петербург

2022

ЗАДАНИЕ НА КУРСОВУЮ РАБОТУ

Студент Кузнецов Н.А.

Группа 1303

Тема работы : AVL-дерево vs Хеш-таблица (двойное хеширование).

Исследование

Исходные данные:

"Исследование" - реализация требуемых структур данных/алгоритмов;
генерация входных данных (вид входных данных определяется студентом);
использование входных данных для измерения количественных характеристик
структур данных, алгоритмов, действий; сравнение экспериментальных
результатов с теоретическими. Вывод промежуточных данных не является
строго обязательным, но должна быть возможность убедиться в корректности
алгоритмов.

Предполагаемый объем пояснительной записки:

Не менее 15 страниц.

Дата выдачи задания: 25.10.2022

Дата сдачи реферата: 23.12.2022

Дата защиты реферата: 24.12.2022

Студент

Кузнецов Н.А.

Преподаватель

Иванов Д.В.

АННОТАЦИЯ

В данной курсовой работе реализованы две структуры данных – AVL - дерево и хеш-таблица, разрешающая коллизии открытой адресации, при этом используя двойное хеширование. Исследовано время, за которое в этих структурах производится вставка, поиск и удаление элемента.

Экспериментальные данные сравнены с теоретическими на основе графиков.

СОДЕРЖАНИЕ

1.	Введение	5
2.	Основные теоретические положения	6
2.1	Сведения о АВЛ-дереве	6
2.2	Сведения о Хеш-таблице	7
3.	Реализация	9
3.1	Реализация АВЛ-дерева	9
3.2	Реализация Хеш-таблицы	10
4.	Сравнение экспериментальных данных с теоретическими	11
4.1	Графики для АВЛ-дерева	11
4.2	Графики для Хеш-таблицы	12
5.	Заключение	15
6.	Список использованных источников	16
7.	Приложение А. Исходный код программы	17

ВВЕДЕНИЕ

Целью данной работы является исследование двух структур данных, это Хеш-таблица с открытой адресацией и АВЛ — дерево. Под исследованием понимается реализация требуемых структур данных/алгоритмов; генерация входных данных (вид входных данных определяется студентом); использование входных данных для измерения количественных характеристик структур данных, алгоритмов, действий; сравнение экспериментальных результатов с теоретическими.

2. ОСНОВНЫЕ ТЕОРЕТИЧЕСКИЕ СВЕДЕНИЯ

2.1 Сведения о AVL-дереве


AVL-дерево - это сбалансированное двоичное дерево поиска, в котором поддерживается следующее свойство: для каждой его вершины высота её двух поддеревьев различается не более чем на 1. Данный факт дает возможность ускорить поиск, вставку и удаление элементов при работе с данным видом двоичных деревьев поиска.

При изменении дерева (с помощью операций вставки или удаления пары), может быть нарушено основное свойство AVL-дерева. Поэтому необходимо после этих действий восстанавливать свойство дерева, это называется балансировкой дерева.


Относительно AVL-дерева балансировкой вершины называется операция, которая в случае разницы высот левого и правого поддеревьев $= 2$, изменяет связи предок-потомок в поддереве данной вершины так, что разница становится ≤ 1 , иначе ничего не меняет. Указанный результат получается вращениями поддерева данной вершины.

Используются 4 типа вращений:


1. *Малое левое вращение.* Данное вращение используется тогда, когда разница высот a-поддерева и b-поддерева равна 2 и высота C \leq высота R




2. *Большое левое вращение.* Данное вращение используется тогда, когда разница высот а-поддерева и b-поддерева равна 2 и высота с-поддерева > высота R.



3. *Малое правое вращение.* Данное вращение используется тогда, когда разница высот а-поддерева и b-поддерева равна 2 и высота C ≤ высота L.



4. *Большое правое вращение.* Данное вращение используется тогда, когда разница высот а-поддерева и b-поддерева равна 2 и высота с-поддерева > высота L.



2.2 Сведения о Хеш-таблице

Хеш-таблица - структура данных, которая позволяет хранить пары (ключ, значение) и осуществлять доступ к элементу по ключу. Где ключ — хеш-значение, которое используется для индексации данных в таблице, а значение — это данные, которые с этим ключом связаны.

Ключ получается в результате обработки данных в некоторой хэш - функции. Этот процесс называется хешированием.

Когда хеш-значение совпадает для разных ключей возникает конфликт, называемый коллизией хеш-таблицы.

Методы борьбы с коллизиями:

- Метод цепочек.
- Метод открытой адресации: линейное и квадратичное исследование, двойное хеширование.

В данной курсовой работе реализовано *двойное хеширование*.

При двойном хешировании используются две независимые хеш-функции $h_1(k)$ и $h_2(k)$

Операции вставки, удаления и поиска в лучшем случае выполняются за $O(1)$, в худшем — за $O(m)$, что не отличается от обычного линейного разрешения коллизий. Однако в среднем, при грамотном выборе хеш-функций, двойное хеширование будет выдавать лучшие результаты, за счёт того, что вероятность совпадения значений сразу двух независимых хеш-функций ниже, чем одной.

3. РЕАЛИЗАЦИЯ

3.1 Реализация AVL-дерева.

Реализован класс *Node*, который будет узловым элементом в дереве. Каждый узел хранит ключ, значение, ссылку на правого и левого ребенка и текущую высоту поддерева, которая считается в ребрах.

Реализован класс *AVLTree*, в котором создается авл-дерево.

Методы:

insert(self, key, value) — вставка ключа и значения в нужное место в дереве.

find(key) - метод поиска узла по ключу.

remove(key) - метод удаления узла по ключу.

findMax() - поиск максимального ключа в дереве

findMin() - поиск минимального ключа в дереве

Также реализованы 4 поворота для балансировки дерева :

small_right_rotate(node) - малый правый поворот

big_right_rotate(node) — большой правый поворот

small_left_rotate(node)— малый левый поворот

big_left_rotate(node) - большой левый поворот

get_height(node) — подсчет высоты для вершины в ребрах

3.2 Реализация хеш-таблицы

class HashTable - реализация хеш-таблицы, имеющая следующие поля: размер таблицы - *size*, количество элементов - *fullness* , массив элементов типа класс *Pair* - *data* и коэффициент заполненности - *fullness_koef*.

Так же класс обладает набором методов.

get_data - получение данных таблицы

print - печать таблицей данных из *data*, с использованием библиотеки *tabulate*

get_size - получение размера таблицы

insert - вставка элемента в таблицу

find - поиск элемента по ключу

delete - удаление элемента по ключу

Некоторые описанные выше *public* методы используют следующие *privat* методы

expand_table - расширение таблицы в случае ее заполнения

hash_func_1 - первая хеш-функция

hash_func_2 - вторая хеш-функция

double_hash - Функция объединяющая *hash_func_1* и *hash_func_2* для двойного хеширования

find_place - нахождения места в *data* для заданного ключа *key*

find_elem - нахождения элемента по ключу, если элемент не найден, то возвращается -1

4. СРАВНЕНИЕ ЭКСПЕРИМЕНТАЛЬНЫХ ДАННЫХ С ТЕОРЕТИЧЕСКИМИ

4.1 AVL-дерево

Теоретические сведения

Сложность выполнения операций зависит от высоты дерева

Операции	Лучший случай	Средний случай	Худший случай
Вставка	$O(1)$	$O(\log n)$	$O(\log n)$
Поиск	$O(1)$	$O(\log n)$	$O(\log n)$
Удаление	$O(1)$	$O(\log n)$	$O(\log n)$

Таблица 1. Сложность действий, AVL-дерево.

Экспериментальные данные

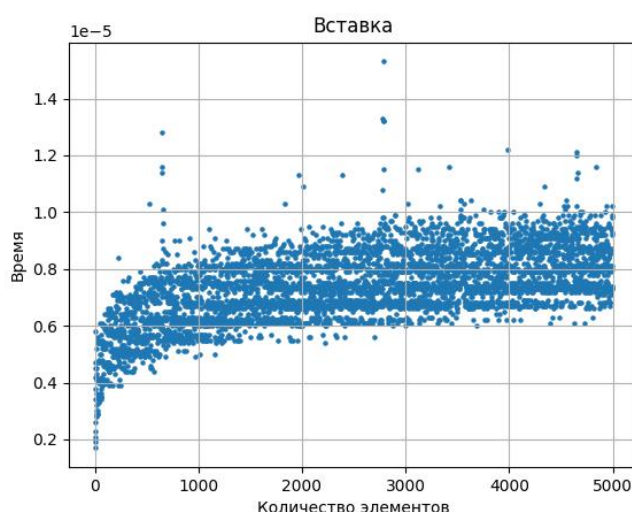


Рисунок 1. - Сложность вставки в AVL-дерево.

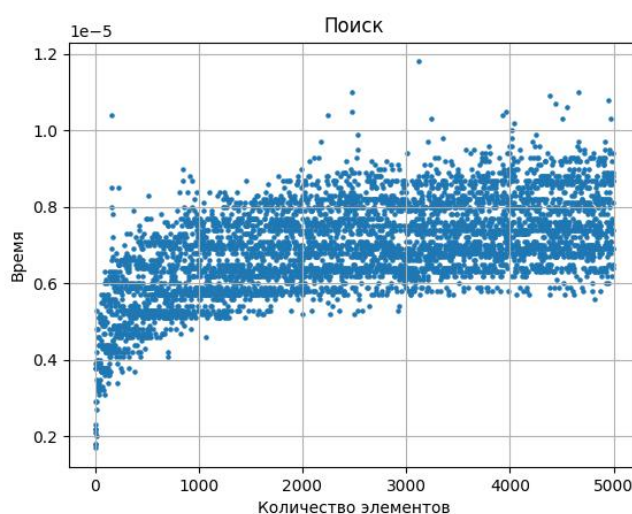


Рисунок 2. - Сложность поиска в AVL-дерево.

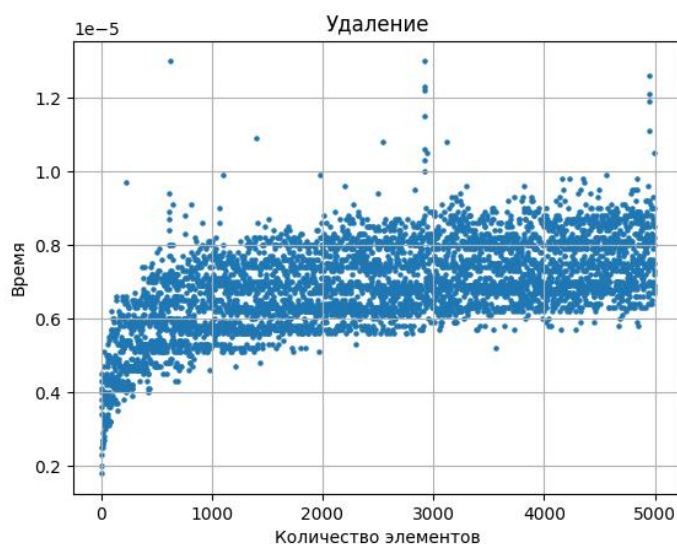


Рисунок 3. - Сложность удаления из AVL-дерева

Сложность операций совпадает с теоретическими данными.

4.2 Хеш-таблица

Теоретические сведения

Сложность выполнения операций зависит от количества коллизий (за которые отвечает коэффициент α) или от количества элементов в таблице.

Операции	Лучший случай	Средний случай	Худший случай
Вставка	$O(1)$	$O(\alpha)$	$O(n)$
Поиск	$O(1)$	$O(\alpha)$	$O(n)$
Удаление	$O(1)$	$O(\alpha)$	$O(n)$

Таблица 2. Сложность действий, хеш таблица.

Экспериментальные данные

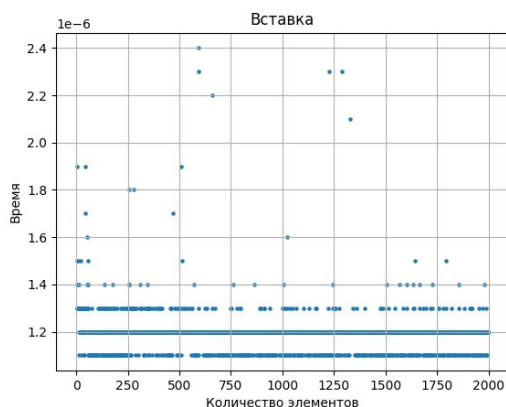


Рисунок 4. - Сложность вставки в хеш-таблицу. Лучший случай.

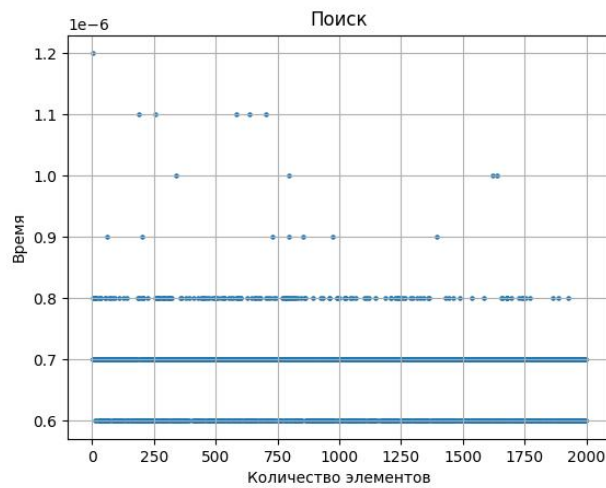


Рисунок 5. - Сложность поиска в хеш-таблице. Лучший случай.

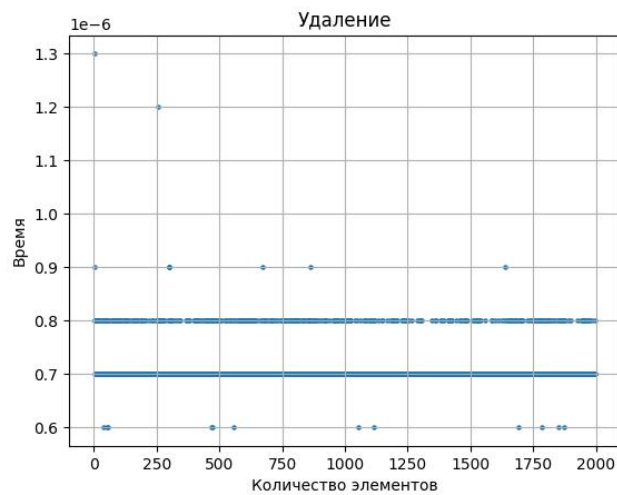


Рисунок 6. - Сложность удаления в хеш-таблице. Лучший случай.

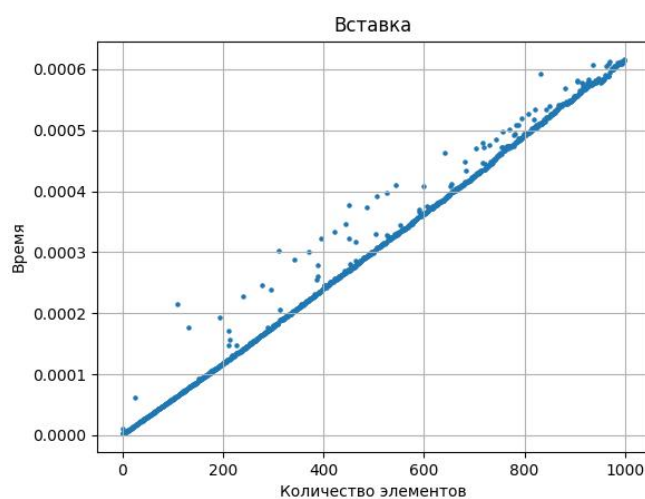


Рисунок 7. - Сложность вставки в хеш-таблицу. Худший случай.

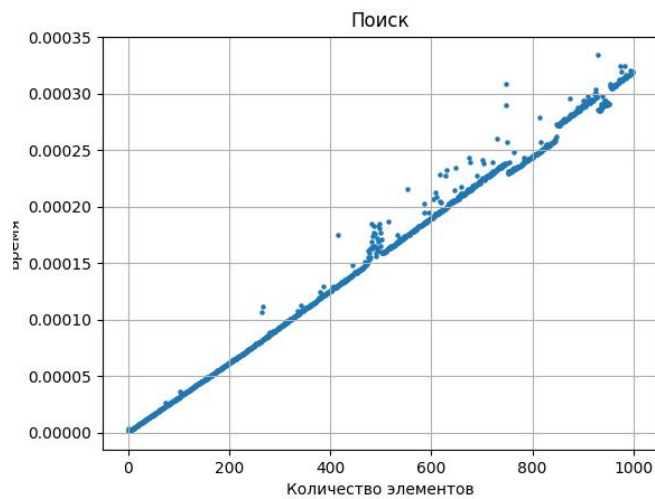


Рисунок 8. - Сложность поиска в хеш-таблице. Худший случай.

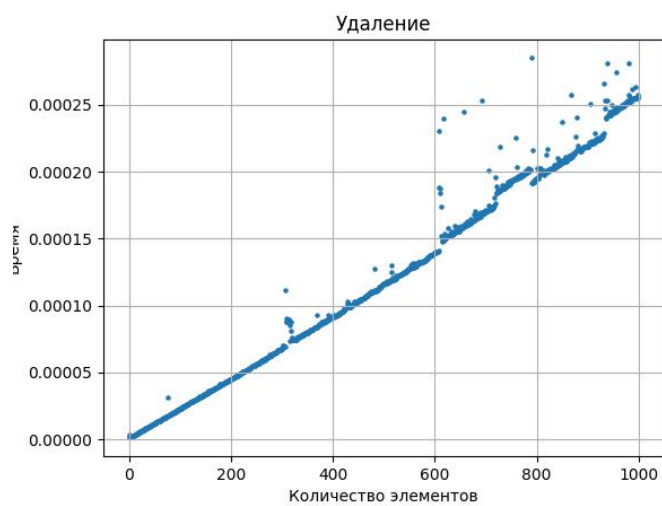


Рисунок 9. - Сложность удаления в хеш-таблице. Худший случай.

Сложность операций совпадает с теоретическими данными.

5. ЗАКЛЮЧЕНИЕ

В ходе курсовой работы были реализованы такие структуры данных, как АВЛ-дерево и хеш-таблица с открытой адресацией на языке Python 3.8.

Были исследованы теоретические положения для данных структур, была протестирована корректность работы этих реализаций, исследовано время работы операций поиска, вставки и удаления для каждой из структур данных.

Было проведено сравнение времени работы данных операций для двух структур данных: исследование подтвердило теоретические оценки на требуемое время для операций.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. "Алгоритмы: теория и практика. <https://stepik.org/course/1547/syllabus>
2. <https://ru.wikipedia.org/wiki/АВЛ-дерево>
3. <https://ru.wikipedia.org/wiki/Хеш-таблица>.

ПРИЛОЖЕНИЕ А

ИСХОДНЫЙ КОД ПРОГРАММЫ

Название файла: avl_tree.py

```
from modules.node import Node

class AVLTree:
    def __init__(self):
        self.root = None

    def insert(self, key, value):
        new_node = Node(key, value)
        if not self.root:
            self.root = new_node
        else:
            self.root = self.insert_rec(new_node, self.root)

    def insert_rec(self, new_node, node):
        if not node:
            return new_node

        if new_node.key < node.key:
            node.left = self.insert_rec(new_node, node.left)
            if abs(self.get_height(node.left) - self.get_height(node.right))
== 2:
                if new_node.key > node.left.key:
                    node = self.big_right_rotate(node)
                else: # key < b
                    node = self.small_right_rotate(node)
            elif new_node.key > node.key:
                node.right = self.insert_rec(new_node, node.right)
                if abs(self.get_height(node.right) - self.get_height(node.left))
== 2:
                    if new_node.key < node.right.key:
                        node = self.big_left_rotate(node)
                    else: # key > b
                        node = self.small_left_rotate(node)

            elif new_node.key == node.key:
                raise ValueError("Ключ со значением {} уже
присутствует".format(new_node.key))

            node.height = max(self.get_height(node.left),
self.get_height(node.right)) + 1
            return node

    def remove(self, elem):
        self.root = self.remove_rec(elem, self.root)

    def remove_rec(self, key, node):
        if node is None:
            raise ValueError("Ключа {} нет в дереве".format(key))
```

```

    if key < node.key:
        node.left = self.remove_rec(key, node.left)
        if abs(self.get_height(node.left) - self.get_height(node.right))
== 2:
            if node.right is None:
                node = self.big_left_rotate(node)
            elif node.right is None:
                node = self.small_left_rotate(node)
            elif key > node.left.key:
                node = self.big_right_rotate(node)
            else:
                node = self.small_right_rotate(node)
        elif key > node.key:
            node.right = self.remove_rec(key, node.right)
            if abs(self.get_height(node.right) - self.get_height(node.left))
== 2:
                if node.right is None:
                    node = self.big_right_rotate(node)
                elif node.left is None:
                    node = self.small_right_rotate(node)
                elif key < node.right.key:
                    node = self.big_left_rotate(node)
                else:
                    node = self.small_left_rotate(node)

        elif node.key == key: # можно удалить из поддеревы большей высоты,
чтобы было меньше балансирования
            if node.left and node.right:
                change_elem = self.findMax_rec(node.left)
                node.key = change_elem.key
                node.left = self.remove_rec(node.key, node.left)
            else:
                if node.right:
                    node = node.right
                    return node
                elif node.left:
                    node = node.left
                    return node
                else:
                    node = None
                    return node
            node.height = max(self.get_height(node.left),
self.get_height(node.right)) + 1
            return node

def findMax(self):
    if self.root is None:
        return None
    else:
        return self.findMax_rec(self.root)

def findMax_rec(self, node):
    if node.right:
        return self.findMax_rec(node.right)
    else:
        return node

```

```

def findMin(self):
    if self.root is None:
        return None
    else:
        return self.findMin_rec(self.root)

def findMin_rec(self, node):
    if node.left:
        return self.findMin_rec(node.left)
    else:
        return node

def find(self, key):
    return self.find_rec(key, self.root)

def find_rec(self, key, node):
    if node is None:
        return None
    if key < node.key:
        return self.find_rec(key, node.left)
    if key > node.key:
        return self.find_rec(key, node.right)
    return node.value

def get_height(self, node):
    if not node:
        return -1
    else:
        return node.height

def small_left_rotate(self, node_a):
    node_b = node_a.right
    Lb = node_b.left
    node_a.right = Lb
    node_b.left = node_a

    node_a.height = max(self.get_height(node_a.right),
self.get_height(node_a.left)) + 1
    node_b.height = max(self.get_height(node_b.right),
self.get_height(node_b.left)) + 1

    return node_b

def small_right_rotate(self, node_a):
    node_b = node_a.left
    Rb = node_b.right
    node_a.left = Rb
    node_b.right = node_a

    node_a.height = max(self.get_height(node_a.right),
self.get_height(node_a.left)) + 1
    node_b.height = max(self.get_height(node_b.right),
self.get_height(node_b.left)) + 1

    return node_b

```

```

def big_left_rotate(self, node_a):
    node_a.right = self.small_right_rotate(node_a.right)
    return self.small_left_rotate(node_a)

def big_right_rotate(self, node_a):
    node_a.left = self.small_left_rotate(node_a.left)
    return self.small_right_rotate(node_a)

```

Название файла: hash_table.py

```

from modules.pair import Pair
import tabulate

```

```

class HashTable:

    def __init__(self):
        self.__size = 8
        self.__fullness = 0
        self.__fullness_koef = 1.7
        self.__data = []
        for i in range(self.__size):
            self.__data.append(Pair())

    def get_data(self):
        return self.__data

    def __str__(self):
        ret_string = ''
        for i in self.__data:
            ret_string += str(i) + '\n'
        return ret_string

    def print(self):
        head = ['key', 'value']
        arr = []
        for i in range(self.__size):
            arr.append([str(self.__data[i].first),
str(self.__data[i].second)])
        print(tabulate.tabulate(arr, headers=head, tablefmt="outline"))

    def get_size(self):
        return self.__size

    def __expand_table(self):
        for i in range(self.__size, self.__size*2):
            self.__data.append(Pair())
        self.__size *= 2

    def __hash_func_1(self, x):
        # return 0
        return x % self.__size

    def __hash_func_2(self, x):
        # return 1
        return x % (self.__size - 1) + 1

```

```

def __double_hash(self, x, i):
    return (self.__hash_func_1(x) + i * self.__hash_func_2(x)) %
self.__size

def __find_place(self, key):
    find_ind = 0
    ind = self.__double_hash(key, find_ind)

    found = False
    while not found:
        if self.__data[ind].is_empty():
            found = True
        else:
            find_ind += 1
            ind = self.__double_hash(key, find_ind)
    return ind

def insert(self, key, value):
    ind = self.__find_elem(key)
    if ind == -1:
        ind = self.__find_place(key)

    self.__data[ind].first = key
    self.__data[ind].second = value

    self.__fullness += 1
    if self.__size < self.__fullness * self.__fullness_koef:
        self.__expand_table()

def __find_elem(self, key):
    find_ind = 0
    ind = self.__double_hash(key, find_ind)

    found = False
    while not found:
        if not self.__data[ind].used and self.__data[ind].is_empty():
            ind = -1
            found = True
        elif self.__data[ind].first == key:
            found = True
        else:
            find_ind += 1
            ind = self.__double_hash(key, find_ind)
    return ind

def find(self, key):
    ind = self.__find_elem(key)
    if ind == -1:
        return 'Not Found'
    return self.__data[ind].second

def delete(self, key):
    ind = self.__find_elem(key)
    if ind == -1:
        print('Cannot be deleted')
    else:

```

```

self.__data[ind].first = None
self.__data[ind].second = None
self.__data[ind].used = True

```

Название файла: node.py

```

class Node:
    def __init__(self, key, value):
        self.key = key
        self.value = value
        self.left = None
        self.right = None
        self.height = 0 # высота считается в ребрах

    def __str__(self):
        left = self.left.key if self.left else None
        right = self.right.key if self.right else None
        return 'key: {}, left: {}, right: {}'.format(self.key, left, right)

```

Название файла: pair.py

```

class Pair:

    def __init__(self, first=None, second=None):
        self.first = first
        self.second = first
        self.used = False

    def is_empty(self):
        if self.first is None or self.second is None:
            return True
        return False

    def __str__(self):
        if self.is_empty():
            return '='
        return f'({self.first} -> {self.second})'

```

Название файла: commands.py

```

from enum import Enum

```

```

class Commands(Enum):
    INS = 1
    FIND = 2
    DEL = 3

```

Название файла: test_avl_tree.py

```

from modules.avl_tree import AVLTree
from modules.commands import Commands
import time
import matplotlib.pyplot as plt
import random

```

```

class TestAVL:
    def __init__(self, kol, cmd):
        self.__kol = kol
        self.__cmd = cmd

    def start(self):

```

```

arr = list(range(self.__kol))
random.shuffle(arr)
plt.xlabel('Количество элементов')
plt.ylabel('Время')
plt.grid()
y = []
x = []
if self.__cmd == Commands.INS:
    plt.title("Вставка")
    avl = AVLTree()
    for i in range(self.__kol):
        t = time.perf_counter()
        avl.insert(arr[i], i)
        y.append(time.perf_counter() - t)
        x.append(i)
    plt.scatter(x, y, s=5)
    plt.show()
    return

avl = AVLTree()
for i in range(self.__kol):
    avl.insert(arr[i], i)

if self.__cmd == Commands.FIND:
    plt.title("Поиск")
    for i in range(self.__kol):
        t = time.perf_counter()
        avl.find(i)
        y.append(time.perf_counter() - t)
        x.append(i)
    plt.scatter(x, y, s=5)
    plt.show()
    return

if self.__cmd == Commands.DEL:
    plt.title("Удаление")
    for i in range(self.__kol):
        t = time.perf_counter()
        avl.remove(i)
        y.append(time.perf_counter() - t)
        x.append(i)
    plt.scatter(x, y, s=5)
    plt.show()
    return

```

Название файла: test_hash_table.py

```

from modules.hash_table import HashTable
from modules.commands import Commands
import time
import matplotlib.pyplot as plt
import random

```

```

class TestHashTable:
    def __init__(self, kol, cmd):
        self.__kol = kol
        self.__cmd = cmd

```

```

def start(self):
    plt.xlabel('Количество элементов')
    plt.ylabel('Время')
    plt.grid()
    y = []
    x = []
    if self.__cmd == Commands.INS:
        plt.title("Вставка")
        arr = list(range(self.__kol))
        random.shuffle(arr)
        h = HashTable()
        for i in range(self.__kol):
            t = time.perf_counter()
            h.insert(i, i)
            y.append(time.perf_counter() - t)
            x.append(i)
        plt.scatter(x, y, s=5)
        plt.show()
        return

    arr = list(range(self.__kol))
    random.shuffle(arr)
    h = HashTable()
    for i in range(self.__kol):
        h.insert(arr[i], i)

    if self.__cmd == Commands.FIND:
        plt.title("Поиск")
        for i in range(self.__kol):
            t = time.perf_counter()
            h.find(i)
            y.append(time.perf_counter() - t)
            x.append(i)
        plt.scatter(x, y, s=5)
        plt.show()
        return

    if self.__cmd == Commands.DEL:
        plt.title("Удаление")
        for i in range(self.__kol):
            t = time.perf_counter()
            h.delete(i)
            y.append(time.perf_counter() - t)
            x.append(i)
        plt.scatter(x, y, s=5)
        plt.show()
        return

```

Название файла: main.py

```

from test_avl_tree import TestAVL
from test_hash_table import TestHashTable
from modules.commands import Commands
from modules.hash_table import HashTable
from modules.avl_tree import AVLTree

```

```

def breadth_first_search(root, dot):
    queue = [root]

```



```

dot.node(str(root.key))
while queue:
    tmp_queue = []
    for element in queue:
        if element.left:
            dot.node(str(element.left.key))
            dot.edge(str(element.key), str(element.left.key))
            tmp_queue.append(element.left)
        if element.right:
            dot.node(str(element.right.key))
            dot.edge(str(element.key), str(element.right.key))
            tmp_queue.append(element.right)
    queue = tmp_queue

def main():
    # FOR EXAMPLE
    h = HashTable()
    h.insert(10, "lol")
    h.print()
    test = TestHashTable(1000, Commands.INS)
    test.start()
    test = TestAVL(500, Commands.INS)
    test.start()

if __name__ == "__main__":
    main()

```